Jev.

소프트웨어의 작은 판단들

의사결정 모델과 Agent Router 비교 데모

Jev 한눈에 이해하기

상황을 읽고,
보기 중에서 고르는 AI

GENERATIVE LLM

문장·코드·설명 생성

JEV / SYSTEM ONE

정해진 답과 판단의 확률

TypeSafe의 의사결정 모델. 코드가 사용할 답의 공간을 개발자가 먼저 정의합니다.

에이전트에서 반복되는 판단

> USER REQUEST
>
> “장애 원인을 분석하고, 최신 정보를 확인한 뒤,
> 필요하면 운영 설정을 변경해줘.”

01	**어느 모델로 보낼까?**	`FAST / STANDARD / REASONING`
02	**검색이 필요한가?**	`needs_web`
03	**승인이 필요한가?**	`needs_approval`

Agent Router는 답변 생성에 앞서 요청의 처리 경로를 결정합니다.

Jev의 입출력과 동작 방식

INPUT

상황 + 타입이 있는 질문

```
state: 긴 업무 요청

questions:
  route           Choice
  needs_web       Noul
  needs_approval  Noul
```

OUTPUT

코드가 읽을 판단 결과

Choice

선택값 + 옵션별 확률 + confidence

Noul

“예”일 확률, 0~1

Score

순서가 있는 등급의 확률 가중 점수

Choice·Score의 confidence는 확률 분포에서 계산합니다. 개별 답의 정답 보장은 아닙니다.

기존 기술과의 차이

기능은 겹칩니다. 무엇을 학습하고 어떤 값으로 반환하는지를 비교합니다.

기술	주로 다루는 문제	Jev와 비교할 지점
Classifier	분류·라벨 선택	질문 정의 방식과 확률 보정
Guardrail	정책·위험 검사	Jev가 수행할 수 있는 판단의 활용 목적
LLM-as-a-Judge	응답 평가·복합 기준 판단	설명·추론 필요 여부와 좁은 질문의 적합성
Structured Output	출력의 스키마 준수	형식 준수와 판단 정확도·불확실성은 별개

일반 LLM도 같은 답을 낼 수 있습니다. 속도·품질·출력 처리 비용은 실제로 비교합니다.

OpenAI Decisions API와 관련 모델

TYPESAFE

Jev / System One

텍스트 상태와 타입이 있는 질문

Choice·Noul·Score

확률 보정에 초점을 둔 의사결정 모델

OPENAI · 2026.09.29 발표

Decisions API

텍스트·이미지 맥락과 질문 집합

미리 정한 유한한 선택지

Luna 기반의 실시간 의사결정 API

로컬 대안 Laya 등 공개 모델도 탐색 가능. Ollama 데모의 API·확률·성능은 각각 확인해야 합니다.

Decisions API는 발표 당시 제한된 프리뷰. 이 발표의 실험 대상은 로컬 Jev-like 라우터입니다.

적용 사례와 활용 지점

실제 유사 사례

Claude Code auto mode

도구 실행 전 classifier가 행동을 평가.
빠른 필터 뒤에 필요한 경우 추가 추론.

Anthropic의 구현이며 Jev 사용 사례는 아닙니다.

공식 활용 패턴

Intent routing

요청을 분류해 일반 코드·전문 LLM·
사람에게 처리 경로를 배정.

우리의 적용 후보

Agent Router / ACE-RTL

라우팅 또는 재시도·검증·종료 판단.
RTL 생성은 기존 생성형 LLM에 유지.

오늘 시연은 Agent Router. ACE-RTL 통합은 적용 아이디어로 구분합니다.

Agent Router 데모 구성

같은 긴 요청, 같은 판단 항목. 라우터 구현을 비교합니다.

SAME REQUEST + SAME DECISION CONTRACT

`route · needs_web · needs_approval`

BASELINE

일반 LLM

로컬 LiteLLM

JSON 생성과 결과 검증·정규화

JEV-LIKE

의사결정 라우터

로컬 Ollama

실제 엔드포인트의 반환 방식에 맞춘 어댑터

CLI에서 나란히 비교 판단 결과 · 시간 · 토큰 · 원본 출력 · 파싱/오류

라우팅 판단까지 비교합니다. 선택된 모델·검색·승인 절차는 실제 실행하지 않습니다.

Agent Router 라이브 데모

SCENARIO · OPERATIONS

> “운영 중인 PostgreSQL에서 오늘 오전부터 응답 지연이 늘었습니다. 첨부한 로그와 설정을 함께 검토해 원인 후보와 확인 순서를 정리해주세요. 사용 중인 버전의 최신 알려진 문제도 찾아보고, 설정 변경이 필요하다면 서비스 영향과 되돌리는 방법을 설명한 뒤 제 승인을 받고 진행해주세요.”

판단할 항목

모델 경로 / 검색 필요 / 승인 필요

시연 순서

대표 요청 → 쉬운 요청 → 직접 입력

여기서 터미널로 전환합니다. 위 문장은 발표용 입력 예시이며 실행 결과를 미리 정하지 않습니다.

측정 결과와 해석

판단의 품질과 처리 비용을 함께 확인합니다.

관찰 항목	일반 LLM	로컬 Jev-like
판단 결과 / 기대값 일치	실행 후 확인	실행 후 확인
요청 시간 · 중앙값	측정 전	측정 전
입력 / 출력 토큰 · 평균	측정 전	측정 전
오류 / 파싱 실패	측정 전	측정 전

현재 실측 데이터 없음. 숫자는 CLI 실행 결과를 받은 뒤 반영합니다.

핵심 질문 **이 판단에 어떤 모델이 적합한가?**

로컬 모델·양자화·서빙 설정을 포함한 실험입니다. Jev 공식 서비스의 성능 비교가 아닙니다.